

2023 年全国大学生信息安全竞赛

作品报告

作品名称：基于 PACS 和联邦学习隐私保护的医学影像分割系统

电子邮箱：1684860039@qq.com

提交日期：2023. 6. 14

填写说明

1. 所有参赛项目必须为一个基本完整的设计。作品报告书旨在能够清晰准确地阐述（或图示）该参赛队的参赛项目（或方案）。
2. 作品报告采用A4纸撰写。除标题外，所有内容必需为宋体、小四号字、1.5倍行距。
3. 作品报告中各项目说明文字部分仅供参考，作品报告书撰写完毕后，请删除所有说明文字。（本页不删除）
4. 作品报告模板里已经列的内容仅供参考，作者可以在此基础上增加内容或对文档结构进行微调。
5. 为保证网评的公平、公正，作品报告中应避免出现作者所在学校、院系和指导教师等泄露身份的信息。

目 录

目 录	③
摘要	1
第一章 作品概述	2
1.1 研究背景	2
1.1.1 人工智能医学影像的市场需求	2
1.1.2 人工智能医学影像的政策支持	2
1.1.3 人工智能医学影像的隐私担忧	3
1.1.4 人工智能医学影像产品面临问题	4
1.2 国内外相关工作	4
1.2.1 人工智能辅助医学图像分割	4
1.2.2 联邦学习	5
1.2.3 联邦学习技术辅助医学图像分割	6
1.3 特色描述	7
1.3.1 联邦学习框架替代传统集中式机器学习	7
1.3.2 基于 AllReduce 聚合的去中心化联邦学习框架	7
1.3.3 基于 TLS1.3 的 trojan 传输协议	8
1.3.4 嵌入 PACS 的系统设计	8
1.4 应用前景分析	9
1.4.1 核心功能	9
1.4.2 应用价值	9
第二章 作品设计与实现	11
2.1 系统方案	11
2.1.1 系统目标	11
2.1.2 系统概述	11
2.2 准备工作	14
2.2.1 基本概念阐释	14
2.2.2 可视化界面的设计	15

2.2.3 原始数据集的选取	18
2.2.4 原始图像处理	18
2.3 关键性技术与工具	20
2.3.1 机器学习库 pytorch	20
2.3.2 图像转换工具 dcm2niix	20
2.3.3 密码库 cryptography	20
2.3.4 基于 DOCKER 的 trojan-go	21
2.4 系统模块设计	21
2.4.1 联邦学习框架下的优化的 ResUnet 神经网络	21
2.4.2 参与方本地训练	23
2.4.3 基于 TLS1.3 改良的 trojan 模型参数传输	26
2.4.4 基于 AllReduce 的分布式计算的 FedAvg 聚合	29
2.4.5 模型效果评价指标确立	32
2.4.6 模型效果全局测试	34
2.4.7 DICOM 与 nii 图像格式转换	36
2.4.8 医学影像和文本数据管理系统的开发	38
2.4.9 可视化用户界面以及作品部署	39
第三章 作品测试与分析	42
3.1 测试方案	42
测试主要分为模型性能测试、系统功能测试两个部分	42
3.2 测试环境的搭建	43
3.3 测试设备	43
3.4 测试数据	44
3.4.1 分割模型性能测试	44
3.4.2 与集中式机器学习的模型比较	50
3.4.3 系统功能测试	51
3.5 结果分析	52
在模型方面	52
第四章 创新性说明	54
4.1.去中心化的联邦学习框架分割图像	54

4.2 基于 TLS1.3 的改良 trojan 安全传输	54
4.3 基于 PACS 的可视化系统打造	55
4.4 低成本、强安全性以及高使用价值	55
第五章 总结	57
5.1 已经完成的工作	57
5.2 存在的不足	58
5.3 以后的工作	58
4. 增加与核心任务相关的系统功能，进一步提高系统的可用性。	59
参考文献	60

摘要

近年来，随着医学影像技术的发展，人工智能医学影像分析系统在国内外市场中大受欢迎。这项技术不仅能够大幅度提高医生阅片和诊断的速度，还可以对影像中的微小之处做到更精准的识别与判断，弥补了医生肉眼阅片的缺陷。

然而目前大部分医学影像AI产品都是基于传统的集中式机器学习框架训练出来的，这造成了数据集获取较难及隐私数据泄露的问题。此外，目前医学影像AI产品还存在着可用产品少、产品性能不稳定以及融入当前医疗体系能力差等多种问题。

为了完善基于集中式机器学习的医学影像分析系统的缺陷，本作品开发了一种基于联邦学习的医学影像语义分割模型。在联邦学习流程中，不需要集中用户数据，用户的数据始终没有离开本地机器。更进一步，我们的作品为解决中央服务器不可信的问题，采用了去中心化的联邦学习框架，使本地模型信息只在用户之间传递，进一步保障了隐私数据安全。同时，我们采用差分隐私技术来避免攻击者可能进行的本地数据还原，采用基于底层进行 sm4 加密，sm3 签名，sm2 传输密钥的基于 TLS1.3 的 trojan 协议防止在网络信道上模型参数流量被检测与干扰。这些措施都能进一步保障模型训练以及模型自身的安全性。

此外，为了改善当前医学影像 AI 产品融入医疗体系能力差且实际可用产品少的问题，本作品基于医学影像领域常用的 PACS 系统开发了可视化服务提供系统。作品首先基于 dcm2niix 开发了图像批量转换工具，实现了传统的 DICOM 图像与模型训练常用的 nii 图像之间的格式转换，打通了接入 PACS 系统的关键壁垒。在系统密码的存储与验证方面，作品采用加盐的 SHA3-512 算法来保障安全性。

经过测试，相较于集中式机器学习，本作品模型的收敛速度下降不大且在测试集上精度较高。而且在加入噪声之后，作品模型的收敛速度与分割精度均有明显优势。在系统功能方面，本作品能顺利完成给定的图像分割任务，并且能有效保护用户隐私，保障数据存储和传输安全，图像格式转换工具也能够流畅批量转换图像，其他各个功能模块均能正常使用。因此，我们认为本作品能在保护隐私安全的同时，高效稳定地完成影像分割任务，具有较强的融入当前医疗体系的能力。

关键词：医学影像，数据隐私保护，联邦学习，融入医疗体系，差分隐私，国密加密

第一章 作品概述

1.1 研究背景

1.1.1 人工智能医学影像的市场需求

人工智能医学影像是以深度学习等新一代人工智能技术,高性能计算能力及医学影像大数据共同促进出现的时代产物,同时也是当今医学发展重要的需求方向。人工智能正在改变医疗健康服务的许多方面,医生是早期采用者。人工智能的迅速发展为医生提供全方位影像判读的支持。人工智能在医学影像在健康管理、诊断、治疗中都有显著作用,有望显著提高疾病诊断、治疗和健康管理的效率、准确性、一致性及可及性。

根据数据显示,2020 年中国人工智能医学影像行业市场规模为 6 亿元。随着市场需求不断增长,新的人工智能医学影像产品的监管审批过程效率提高,中国的人工智能医学影像解决方案市场**预期将进入爆发式增长期**。预计到 2025 年中国人工智能医学影像行业市场规模将增长至 442 亿元,2020-2025 年复合年增长率为 135.9%。




图 1-1 中国 AI 医学影像市场增长预测

1.1.2 人工智能医学影像的政策支持

近年来,人工智能医学影像产业获得广泛的政策支持。随着机器学习和深度学习

技术的迅猛发展，人工智能在医学图像处理和模式识别方面取得了重大突破。深度神经网络的出现使得计算机能够学习和理解复杂的图像特征，并在医学图像处理中展现出了巨大的潜力。根据卫健委 2022 年印发的《关于加快场景创新以人工智能高水平应用促进经济高质量发展的指导意见》，人工智能已经成为医学科技装备领域的重要战略发展方向。

除了国家层面出台政策外，各省市也相继出台了相关政策促进人工智能产业的发展。从各省市及自治区发布的规划政策来看，强调人工智能产业与传统行业的融合是政策扶持的重点。目前，人工智能在医学图像领域的应用主要包括图像分割与标注、病变检测和诊断、图像增强和去噪等方面，仍然有巨大的发展空间。

1.1.3 人工智能医学影像的隐私担忧

目前而言，人工智能辅助医学图像分割的应用需求虽然广，但仍存在着一些严重的问题，其中最为重要的一点就是医学图像分割系统容易造成**患者隐私数据泄露等安全问题**。根据德国 Greenbone 公司在 2019 年 9 月提出的信息安全报告“Confidential patient data freely accessible on the internet”，全世界有大约 2430 万条医疗数据处于可以被轻易获取的泄露状态。根据估计与这些被泄露的医疗数据相关的医学图像有超过 7 亿张，这些医学图像可以被随意地访问、查看和下载。医疗隐私的泄露会导致患者受到骚扰、经济利益受损，甚至影响到患者的身心健康，因此加强对医疗隐私的保护迫在眉睫。

网上问诊：隐私泄露难防，维权标准待定

柳姗姗

2021年04月15日09:40 来源：《工人日报》

阅读提示

快速发展的互联网医疗，为患者看病吃药带来很多便利，但防不胜防的信息泄露问题却让人难掩隐忧。有律师表示，互联网医疗的患者隐私权保护维权案例还属凤毛麟角，主要原因在于患者可能并不知道个人信息已被泄露或泄露后应参照什么样的标准进行维权。

“生活在小城市，想到大城市去好医院看次病，交通、挂号、排队都要耗费不少精力，网上问诊确实方便，但就怕隐私信息被泄露。”近日，身患疾病的吉林四平市民王丽（化名）在当地医院久治无明显效果后一直想到更好的医院看看，但因工作太忙、专家号难挂，便开始考虑网上远程问诊。

图 1-2 医疗隐私泄露问题严重

1.1.4 人工智能医学影像产品面临问题

当前人工智能医学影像产品虽然有着广阔的市场以及强有力的政策支持，但仍然存在着诸多问题。根据《中国医学影像人工智能发展报告（2021-2022）》，当前医学影像 AI 产品面临主要的三大问题为：

- (1) 实际可应用产品少；
- (2) 不能很好嵌入现有医学影像诊疗流程；
- (3) 产品性能不可靠。

对于医学影像 AI 系统开发者来说，获得足够的数据集是能否开发出优秀产品的关键，但现实情况是，医院等优质影像数据的拥有者出于保护患者隐私的需要往往不会向外界提供足够的数据集用于训练模型，这在很大程度上影响了产品的性能。此外，医学界与人工智能产业界的脱钩也一定程度上造成了现有产品嵌入医学影像诊疗流程差的问题。同时，当前医学影像 AI 产品应用部位主要是冠脉、头颈、骨等，AI+超声、AI 应用于肝部、乳腺和 AI 应用于临床是当前 AI 医学影像赛道的市场机遇。




图 1-3 人工智能医学产品应用部位集中

1.2 国内外相关工作

1.2.1 人工智能辅助医学图像分割

人工智能技术的运用对于医学图像分割具有重大的意义和应用价值，特别是基于

深度学习的卷积神经网络算法有助于提高分割效率、缩短分割时间、减少主观偏差，可以将医生的精力从图像分割中解放出来。近几年一些研究表明，通过对经典卷积神经网络模型的改进可以在医学图像上对一些复杂组织结构达到很好的分割效果。

香港中文大学 Li 等于 2018 年提出的混合密集连接网络(H-DenseUNet)在肝脏分割方面取得了非常好的效果，很好地解决了同时分割肝脏和病灶的问题。同年，ZHAO 等^[4]研究团队通过将全卷积神经网络(fully convolutional neural networks, FCNN) 和条件随机场(conditional random fields, CRF)集成到统一框架中，开发了一种新的脑肿瘤分割方法，获得了具有外观和空间一致性的较好的分割结果。

近年来 U-Net 在医学图像分割领域的出现不断增加，由于其灵活性、优化的模块化设计和在所有医学图像模式中的成功，**U-Net 已经成为最广泛应用的图像分割体系结构**。2022 年，来自德国亚琛工业大学的 Azad R 等学者发表了综述《Medical image segmentation review: The success of u-net》。在这篇综述中，作者对 U-Net 及其变体的文献进行了全面回顾，从它的主要分类、扩展到变体，以及性能和速度的基准进行了研究，同时为了构造各种各样的 U-Net 扩展，根据对体系结构所做的更改的类型对不同的扩展和变体进行了分组。本作品将从 U-Net 族中挑选合适的模型实现具体的图像分割。

1.2.2 联邦学习

联邦学习概念最早由谷歌在 2016 年提出并应用，**其核心内容在于分布式计算和隐私保护**。传统的联邦学习框架由中央服务器和多个客户端组成，其中每一个本地客户端都有自己的本地数据集，其核心过程可以分为 4 步：首先是每个参与的用户利用本地数据进行训练，然后将本地训练好的模型参数或者参数更新梯上传给中央服务器。第二步就是中央服务器使用特定的算法对每个用户上传的模型参数进行聚合，并根据聚合后的结果来更新全局模型。在这个过程中，用户向中央服务器上传的是本地训练的模型参数，而不是本地的数据，这就保证了用户数据的隐私安全。因为就目前的研究而言，攻击者或者中央服务器很难根据神经网络模型参数或梯度来还原出用户的训练时所使用的数据。同时，服务器根据多个用户上传的结果来聚合。对于生成的全局模型来说，它包含了每个用户的本地模型信息。这样的效果就相当于使用了每个用户的数据集进行训练。第三步就是服务器将更新后的全局模型下发给每个用户。

最后用户再根据各自的需求来更新本地模型。更新后的本地模型由于吸收了所有数据集的信息，因此变得更加精确可靠。




图 1-4 联邦学习用于医疗场景

2021 年，Qinbin Li 等人发表了名为《A Survey on Federated Learning Systems: Vision, Hype and Reality for Data Privacy and Protection》的论文，深入介绍了联邦学习的基本框架以及其分类，并且对**联邦学习在数据隐私和数据保护等方面的优越性**进行了说明。同时，文章认为目前联邦学习也面临这诸如不切实际的系统假设、可扩展性差和效率低等诸多方面的挑战。为了应对这些挑战，有学者对传统的联邦学习框架进行了改进，提出了去中心化的联邦学习框架，以进一步降低联邦学习对中央服务器的依赖。2020 年，Lu S 等人利用去中心化的非凸优化的联邦学习，从真实世界的非同分布的医院数据集中提取患者的特征，基于大型的真实世界的电子健康记录数据库的多重数值仿真，证明了去中心化联邦学习与经典方法相比的优越性。

由此可见，经过近几年的发展，联邦学习已经发展成为一个较为成熟的技术，并在各个领域中得到广泛的应用。

1.2.3 联邦学习技术辅助医学图像分割

虽然学界对人工智能辅助医学图像分割以及联邦学习的相关研究，但将联邦学习具体应用在医学图像分割时仍然存在着大量问题，例如：虽然联邦学习可以使用不同医院拥有的孤立患者数据协作训练深度学习模型，用于各种临床应用，包括医学图像分割。然而，联邦学习的一个主要问题是它在处理非独立同分布（非 iid）的数据时会出现性能下降，这在医学图像中经常出现；此外，虽然联邦学习允许分布式医疗机构协作学习具有隐私保护的共享预测模型，但是在临床部署中，在联邦学习中训练的

模型在应用于联邦之外完全看不见的医院时仍然会出现性能下降，如何让联邦学习可以直接泛化到看不见的目标域成为一个问题。

针对第一个问题，Xu X 等学者提出了联合交叉学习 (FedCross)，以解决这一具有挑战性的问题，并且验证了在一组公共数据集上，论文所提出的 FedCross 训练策略在非独立同分布数据上优于主流 FL 方法。

针对第二个问题，Liu Q 等学者在元学习(Meta Learning)和对比学习(Contrastive learning)的背景下，提出了一个隐私保护的策略来提高联邦学习模型的泛化性，即通过高效的连续频域插值算法。他们方法的有效性通过在两个医学图像分割任务上优于现有技术和深度消融实验的卓越性能得到证明。

基于此，我们完全可以将联邦学习框架应用于医学图像分割中，以期在不同场景下保持较高分割准确率的同时有力地保障患者的隐私安全。

1.3 特色描述

1.3.1 联邦学习框架替代传统集中式机器学习

与传统集中式机器学习相比，联邦学习框架具有**更强的隐私保护能力**。本作品利用联邦学习固有的数据隐私保护、减少数据传输、分散风险与攻击难度和**去中心化控制**等特点，能从底层框架上提升模型对患者隐私数据的保护能力。




图 1-5 联邦学习基本原理

1.3.2 基于 AllReduce 聚合的去中心化联邦学习框架

中心化的联邦学习框架虽然能从底层上提升对患者的隐私安全保护能力，但是其

运行**仍然依赖着中央服务器**：一旦中央服务器停止工作，整个联邦学习框架便无法继续运行；此外，考虑到服务器包含了所有用户上传的模型梯度信息，所以其很有可能遭受攻击，从而导致拒绝服务或者提供错误的模型。为了解决这个问题，本作品对一般的联邦学习流程做了一些改变，使其聚合过程不再依赖于服务器。我们的作品采用了 **AllReduce** 的聚合策略，使每个用户的本地模型的梯度只在用户之间相互传递，从而避免了针对联邦学习的中央服务器的攻击带来的问题。

1.3.3 基于 TLS1.3 的 trojan 传输协议

Trojan 是目前比较新的一种协议，Trojan 的设计理念与传统协议的设计理念相反，Trojan 不使用强加密和随机模糊，而是直接模仿互联网最常见的协议 HTTPS，以此来达到设计的目的。HTTPS 协议本身就含有加密，而且 TLS 1.3 更是强加密，现今无法通过简单方式破解。**Trojan** 本身使用了 HTTPS 的特性，自带了加密和混淆的属性。

1.3.4 嵌入 PACS 的系统设计

医疗影像 PACS 系统（Picture Archiving and Communication System）是一个医疗信息系统，用于存储、检索、传输和显示医疗影像。它可以集成多种医疗设备，如 X 光机、CT、MRI、超声等，将这些设备产生的数字影像转换成标准格式，进行存储和管理，以便医生和专业技术人员进行诊断和治疗。目前，PACS 系统已经被各大医院广泛使用，并纳入其医疗体系中。



图 1-3 PACS 系统基本原理

为了解决目前医学影像 AI 产品面临的与当前医疗体系脱钩的问题，我们将系统

嵌入 PACS 中进行开发,在全系统开发过程中考虑与当前医疗体系接轨,在利用 PACS 影像数据的同时将分割好的图像重新存入系统当中,使得医院不需要再重新使用一套新的系统,降低了使用系统的成本。

此外,由于 PACS 系统将数据等敏感信息均存储在本地,这与联邦学习的特征不谋而合。这种特征保证了医院能够掌握自身的医学影像数据,解决了医院对数据泄露的担忧。

1.4 应用前景分析

1.4.1 核心功能

本系统主要目的是打造一款能够保护好患者隐私安全的易于使用的影像分割系统。为此,我们选择了去中心化的联邦学习作为框架训练模型完成分割,同时基于 PACS 完成系统开发并提供图像转换功能。为了进一步保障模型聚合传输的安全,我们利用基于 TLS1.3 的改良 trojan 进行数据传输。此外,我们还严格分配了用户权限,并额外增加了健康知识小贴士。

本系统部署在 web 端,同时支持手机端,主要面向医生、患者以及医院管理员这三类人群提供服务。系统的核心功能为肝脏分割模型的训练以及提供分割服务。

1.4.2 应用价值

鉴于当前医学影像 AI 产品存在着实际可应用产品少、嵌入现有医学影像诊疗流程差、产品性能不可靠这三大问题,我们从产生问题的根源出发,分析了产生这些问题的主要原因为训练模型可用数据缺乏、开发人员不了解当前医疗实际等。

为了解决这些问题,本产品做出了以下贡献:

- (1) **利用去中心化的联邦学习作为模型框架:**这一框架的优越之处在于影像数据不脱离本地即可完成模型训练,这一特性从模型上增强了产品的隐私保护能力,同时降低了数据拥有者的隐私担忧,使联邦训练可以更为容易获得参与方地信任继而获得足够多的数据。
- (2) **嵌入 PACS 系统进行产品开发:**PACS 系统是当前最为广泛使用的医学影像管理系统,基于 PACS 开发能够良好的对接当前医学影像诊疗体系,同时,应用图像转换工具进行影像文件与模型训练数据之间的格式转换。此外,我们增加了

健康知识科目栏目，进一步提高系统可用性。

(3) **采用多种措施完善数据保护能力：**向训练的图像中添加噪声、加盐的 SHA3-256 进行加解密、利用基于 TLS1.3 改良的 trojan 进行模型参数传输。

综上，本作品将在保证分割精度的同时，最大可能保障隐私数据安全，打造一款切实可用、能够融入当前医疗体系的产品。

第二章 作品设计与实现

2.1 系统方案

2.1.1 系统目标

本系统的主要目的是在完成影像分割任务的同时增强全过程的隐私安全性，并努力解决当前医学影像 AI 产品存在的问题。为此，本系统搭建了基于联邦学习的肝脏影响分割模型来完成分割任务。此外，采取通信传输加密、添加噪声等措施进一步增强模型的安全性。

针对目前医学影像 AI 产品存在的实际可应用产品少、嵌入诊疗流程能力差、产品性能不可靠以及医学影像领域普遍存在的隐私泄露等问题，我们的系统在利用联邦学习框架提高隐私保护能力的同时，采取通信传输加密、添加噪声等措施进一步增强模型的安全性。此外，我们将基于现存的医疗影像体系开发我们的系统，使之能更好的融入当前的医疗体系。

同时，本作品打造过程可视化的 B/S 架构用户界面，为使用者带来更好的用户交互体验，降低使用门槛。我们的作品将对每名用户登录或者注册时进行身份验证。患者和医生都首先需要在注册账号时完成实名身份认证，患者在首次登陆时会自动与其主治医生进行医患关系绑定，在患者上传其医学影像信息并由系统分割完成后，其对应的主治医学能看到系统辅助分割的结果，并将结果用在临床诊断中。值得注意的是，除了患者本人和对应的主治医生，其他任何身份（其他患者、其他医生以及系统管理者）均无法查看到患者的病灶信息。在系统管理者的页面中，所有数据均进行了脱敏处理以保证管理者不能窃取患者隐私信息。

本系统希望能成为一个切实可行的平台，解决医院等平台对隐私泄露的担忧，推动医学影像 AI 产品的发展进步。

2.1.2 系统概述

整个系统主要分为两个部分：一是分割模型开发，二是服务提供系统开发。

具体来讲，分割模型采用去中心化的联邦学习框架对肝脏部位分割进行学习，以期开发出高精确度、高隐私性的模型。在这个模型的训练过程中，我们采用多种方式

来提高模型的隐私保护能力。整个分割模型的开发工作由客户本地训练模块，模型梯度聚合模块以及全局模型测试模块这三个模块构成。




图 2-1 模型开发三大模块

其中，客户本地训练模块负责在本地客户端更新本地模型，并将更新结果上传；梯度聚合模块负责将各客户机训练产生的本地更新进行聚合，并将聚合的结果分发给各个参与方；全局模型测试模块将对每次聚合后的模型进行效果验证，直到分割精度趋于不再提升时停止模型训练，得到最终模型。这个模型可以用于处理临床场景下的肝脏图像分割任务，辅助医生完成临床诊断。被正确分割的图像可以用于新一轮的模型训练当中。




图 2-2 模型训练思路流程图

在服务提供系统开发部分中，我们将训练好的模型装载在服务器中对患者上传的肝脏图像进行分割，并将原始图像以及分割好的图像保存在数据库中。同时，我们开发权限控制的用户管理系统来控制浏览器中请求服务器数据的行为以完成系统对不同用户的权限控制，增强患者隐私保护能力。我们将所有功能嵌入 PACS 系统中进行开发，设计专门的图像格式转换工具以及单独的服务器提供可视化服务。此外，我们还增加了健康知识科普栏目。总之，用户在使用时会先登录我们的门户网站，并由此跳转到模型分割、联邦聚合、用户管理以及健康贴士这四个部分以获得不同的服务。




图 2-3 服务提供系统开发思路

2.2 准备工作

2.2.1 基本概念阐释

联邦学习：一种机器学习技术，具体来说就是人们在多个拥有本地数据样本的分散式边缘设备或服务器上训练算法。这种方法与传统的集中式机器学习技术有显著不同，传统的集中式机器学习技术将所有的本地数据集上传到一个服务器上，而更经典的分散式方法则通常假设本地数据样本都是相同分布的。

参与方：在联邦学习中，参与方是指那些拥有本地数据并参与模型训练的实体或设备。这些参与方可以是个人用户、边缘设备、移动设备、医疗机构、企业等。每个参与方在其本地环境中进行模型训练，而不需要将数据共享到中央服务器或与其他参与方交换原始数据。在我们的作品中，参与方一般为医院等医疗机构。

ResUnet：ResNet 是一种非常成功的深度卷积神经网络结构，其具有较强的特征表达能力和较浅的网络深度，使得其在图像分类等任务中表现出了出色的性能。因此，将 ResNet 作为 encoder 替换 U-Net 原始结构，可以使 U-Net 在图像分割任务中获得更好的性能表现。

AllReduce 算法：深度学习领域最常用的集合通信元语，主要用于多机/多卡之间的梯度同步，目标是高效得将不同机器中的数据整合（reduce）之后再把结果分发给各个机器。目前常见的实现算法是基于 Ring 的 AllReduce，英伟达的 NCCL 通信库采用了这种算法，该算法每次跟相邻的两个节点进行通信，每次通信数据总量的 N 分之一。

PACS 系统：医疗影像 PACS 系统（Picture Archiving and Communication System）是一个医疗信息系统，用于存储、检索、传输和显示医疗影像。它可以集成多种医疗设备，如 X 光机、CT、MRI、超声等，将这些设备产生的数字影像转换成标准格式，进行存储和管理，以便医生和专业技术人员进行诊断和治疗。

Trojan:目前比较新的一个服务协议，不使用强加密和随机模糊，而是直接模仿互联网最常见的协议 HTTPS，以此来达到不被防火墙检测到的目的。

2.2.2 可视化界面的设计

为了更好的将模型的分割结果展示出来以及增强使用的便捷性，本作品开发了专门的可视化 WEB 页面俩提供服务。

首先是产品门户界面，包含了对于系统的介绍以及具体功能跳转入口，经由图 2-5 所示的四个按钮可以跳转到不同的功能区域。



图 2-4 系统门户界面 1



图 2-5 系统门户界面 2



图 2-5 系统门户界面 3

健康贴士栏目界面如下，可以在看完后自动跳转到下一篇文章：



在宣传界面可以点击登录或者注册的连接跳转到登录界面：



图 2-5 系统登录界面

最为关键的是医生界面，医生可以在其页面看到他所负责的所有患者的医学影像并进行批注：




图 2-6 医生界面

最后，我们还在文章末尾设立了意见反馈渠道：

你对本系统满意吗

☐ 满意
☐ 不满意
☐ 还行

投票

查看

欢迎给我们留言

请填写您的姓名

请填写您的电话

请填写您的手机号

请填写您的QQ

请填写您的邮箱

请填写留言信息

提交留言

欢迎给我们留言

尚未有留言

共有0条留言

2.2.3 原始数据集的选取

由于医学影像数据的隐私敏感性，相关医院以及研究所很少大批量公开医学影像数据，获取数据集的难度较高。

本作品在训练、验证以及测试模型的过程中所使用的数据集为 MICCAI 2017 LiTS 数据集。该数据集来自于 2017 年由慕尼黑理工大学、以色列特拉维夫大学等高校、研究院所以及 IEEE 生物医学成像国际研讨会（ISBI）2017 和国际医学影像计算和计算机辅助干预协会（MICCAI）2017 合办的肝脏肿瘤病灶区 CT 图像分割挑战（Liver Tumor Segmentation Challenge）大赛。数据集中包含 130 张待分割的 CT 图像以及 130 张与这些图像对应的标签（分割结果）。这些原始图像数据和分割结果来自于世界各地的不同临床现场。

其中图像的文件图片拓展名为 nii，其文件类型为 NIfTI-1 Data Format，是一种专门的医学影像文件格式，可以使用 ITK-SNAP 等专业的图像阅读软件查看。

2.2.4 原始图像处理

在正式的训练之前，需要将用户本地数据集中的数据读入并封装好。考虑到本作品神经网络中的运算都是基于张量的，所以在该模块读入原始数据之后，需要对原始数据进行一系列的处理，使其变换为能够被神经网络的运算所支持的形式。

首先我们需要对**图像进行预处理**，将原始数据转换为具有重点区域的固定数据，这一阶段包括以下步骤：

- (1) 灰度值裁剪：根据预先设定的阈值，裁剪掉原始图像中阈值之外的灰度值。
- (2) 降采样：对图像的 x 和 y 轴进行降采样，并将 slice 轴的 spacing 归一化到 slice_down_scale。
- (3) 区域定位：确定包含所需研究区域起始和结束的 slice，并对每个 slice 进行扩张。如果 slice 的大小不满足最小要求，放弃该区域并寻找下一个区域。
- (4) 保存预处理数据：将预处理后的数据按照 nii 文件格式保存。

接下来是 Dataset 类的定义和图像读取实现。Dataset 类用于读取和处理数据，并定义了图像的转换方式。读取医学影像的 nii 格式时，我们使用 SimpleITK 库中的函数。以下是读取的步骤：

- (1) 使用 SimpleITK 中的 ReadImage 函数读取本地的 nii 格式数据。
- (2) 使用 SimpleITK 中的 GetArrayFromImage 函数将读取到的图像转换为数组格式。
- (3) 对数组进行归一化处理。
- (4) 使用 torch 库中的 FloatTensor 函数将数组转换为张量 (Tensor)。
- (5) 对张量应用定义好的图像变换。

最后是图像变换的实现。图像变换包括随机裁剪 (RandomCrop)、左右随机翻转 (RandomFlip_LR)、上下随机翻转 (RandomFlip_UD) 和添加高斯噪声 (AddGaussianNoise) 四种方式。这些变换的目的是增强数据，使模型能够在经过一些变换后仍能进行准确的分割和预测，同时保护患者隐私。前三种变换可以直接使用 torchvision.transform 库中的函数实现。添加高斯噪声稍微复杂一些。其大致步骤如下：

- (1) 根据设定的均值、方差、概率等参数，生成一个随机值序列 N。
- (2) 将 N 扩展为与图像形状相同的张量或数组。
- (3) 将 N 与目标图像的数组相加，实现对图像的噪声扰动。

通过图像处理模块进行数据增强和添加噪声后，图像中引入了随机信息，使攻击者难以分辨真实信息与随机添加信息，从而有效保护患者隐私。




图 2-7 四种 transform 的方式

2.3 关键性技术与工具

2.3.1 机器学习库 pytorch

PyTorch 是一个开源的机器学习框架，专注于深度学习任务。它由 Facebook 的人工智能研究团队开发，并于 2016 年首次发布。PyTorch 提供了一个灵活、易于使用且功能强大的框架，使研究人员和开发者能够更轻松地进行构建、训练和部署深度学习模型。它在学术界和工业界都得到了广泛的应用，并被认为是深度学习领域的重要工具之一。我们将依托于 pytorch 开发我们的模型。

2.3.2 图像转换工具 dcm2nii

Dcm2nii 是一个开源的图像转换工具，能够实现主流的医学影像数据格式 DICOM 与科学研究深度学习中常用的医学影像数据格式 nii 的相互转换。本作品将使用其作为重要工具，用来实现本系统对 PACS 系统的嵌入。

2.3.3 密码库 cryptography

cryptography 是一个功能强大且易于使用的 Python 密码学库，它提供了许多密码

学相关的功能，包括对称加密、公钥加密、哈希函数、消息认证码、数字证书、随机数生成等。它建立在 Python 的标准库 cryptography.hazmat 之上，提供了更高级的接口和易用性。

2.3.4 基于 DOCKER 的 trojan-go

Trojan-Go 是一种基于 Go 语言开发的高性能代理工具，它能够在网络上建立加密的隧道连接，并隐藏真实的网络流量，提供更安全和私密的网络访问。在结合 Docker 使用时，可以方便地部署和管理 Trojan-Go 服务。

2.4 系统模块设计

2.4.1 联邦学习框架下的优化的 ResUnet 神经网络

我们作品中采用的是 3DUnet 族中的 ResUNet。Unet 网络族常用于对图像的语义分割，其特点是它采用了编码（encode）+解码（decode）的结构，先对图像进行多次卷积层块运算（conv+Relu+pooling）下采样，再进行上采样，并裁剪之前的低层 feature map，与上采样后的 feature map 进行融合，重复上采样+融合过程直到得到与输入图像尺寸相同的分割图。其结构示意图如下图所示。因其形状类似 U 型，所以被称为 Unet。




图 2-8 Unet 原理图

但是纯粹的 Unet 在医学影像这种要求高精度的应用场景中的表现不是特别好，尤其是当成像过程中收到外界光源的干扰时，会使结果的对比度显著降低，导致分割边界不清晰。而 ResUNet 为解决图像退化（收到外界因素干扰）的问题，采用了残

差学习的策略。残差学习的原理图如下图所示，相比于直接学习的方式，残差学习可以更高效地提取出图像的特征。




图 2-9 残差学习示意图

残差学习中，模型对 X 训练，得到 $F(X)$ ，将 $H(X)=F(X)+X$ 作为输出。当残差（ $F(X)$ 与 X 的差值）为 0 时，此时堆积层仅仅做了恒等映射，至少网络性能不会下降，实际上残差不会为 0，这也会使得堆积层在输入特征基础上学习到新的特征，从而拥有更好的性能。将该思想应用到 Unet 中去，即在下采样和上采样的过程中，每经过一个卷积块，都进行一次残差学习，将残差学习的结果作为下一个块的输入。




图 2-10 ResUNet 结构

同时，由于传统的 ResUNet 通常使用随机梯度下降（SGD）等优化算法进行模型训练，考虑到联邦学习的诸多特征，SGD 可能会存在模型收敛能力下降以及模型泛化性较弱。本作品采用了 SAM（锐度感知最小化）优化器，SAM 将重点放在领域内寻找均有均匀的低损失值的参数上，由于计算领域参数而不是计算单个参数，损失超平面

比其他优化方法更为平坦，这反过来增强了模型的泛化。大量实验结果表明，与 SGD 等优化器相比，用 SAM 训练的相同的 ResNet 收敛到一个更为平坦的最小值，这是泛化性增强的体现。




图 2-11 SAM 参数更新模式

2.4.2 参与方本地训练

本模块要实现的功能就是每个用户对本地数据进行训练，并更新本地模型。除了 2.4.1 中采用 SAM 优化算法的 ResUnet 神经网络，该模块实现的关键部分还包括：评估指标，早停（Early-Stop）机制，深监督策略。

首先是评估指标的确立，我们选择的评估指标是 Tversky 系数，其表达式如下：

$$T(A, B) = \frac{|A \cap B|}{|A \cap B| + \alpha |A - B| + \beta |B - A|}$$

其中，A 和 B 分别表示预测结果集合和真实情况（标签值）集合， α 和 β 为设定的参数。通过调整 α 和 β ，可以控制假阳性和假阴性之间的平衡。

对模型进行训练的过程本质上是对模型的参数进行学习更新的过程，参数学习的过程中往往会用到一些迭代方法，如梯度下降（Gradient descent）学习算法。但值得注意的是，由于每个用户的数据集各不相同，所以训练出来的模型也不相同。这样就会带来一个问题：我们不好确定每个用户训练的 epoch 数值（一个 epoch 表示对所有的训练数据的一轮遍历）应该设置为多少。如果设置过低，则模型没有充分被训练，表现效果就很差；如果过高，则模型可能出现过拟合的情况，在其他数据集上的表现也不好。在实际处理中，一般会将 epoch 设定为一个较大的值来提高模型训练效果，因此，我们需要通过其他方法才解决过拟合问题。Early-Stop 便是一种迭代次数截断的方法来防止过拟合的方法，即在模型对训练数据集迭代收敛之前停止迭代来防止过拟合。Early-Stop 方法的具体做法是，在每一个 epoch 结束时

计算验证数据的准确率，当准确率不再提高时，就停止训练。一般的做法是，在训练的过程中，记录到目前为止最好的验证准确率，当连续 30 次 Epoch（或者更多次）没达到最佳准确率时，则可以认为准确率不再提高了。此时便可以停止迭代了。

Early-Stop 策略的效果如下图所示，可以看到，较好地解决了过拟合问题。




图 2-11 Early-Stop 策略

同时，我们采用了深监督(Deep Supervision)策略，在深度神经网络的某些中间隐藏层加了一个辅助的分类器作为一种网络分支来对主干网络进行监督的技巧，用来辅助解决深度神经网络训练梯度消失和收敛速度过慢等问题。

基于以上所有算法以及策略，我们可以实现模型在本地的训练，模型在客户端本地的训练过程如下：

1. 加载 `config.py` 中的参数
2. 加载数据
3. 初始化模型：ResUNet
4. 选用 Adam 优化器、TverskyLoss、Early-Stop 策略。
5. 每轮 epoch 中，调整学习率 lr (每 20epoch, lr 变为原来 1/10)。

`train()`

进入模型训练模式(`model.train`)

定义 loss 和 dice

遍历数据集

拆分成 `data`(分割前肝脏图片)和 `target`(分割后肝脏图片)

对 `target` 进行独热编码
将模型的参数梯度初始化为 0
将 `data` 输入模型，得到 `output`
计算损失: $\text{loss} = \text{loss3} + \alpha * (\text{loss0} + \text{loss1} + \text{loss2})$
对 `loss` 反向传播计算梯度
`optimizer.step()` # 更新所有参数
更新 `loss`
更新 `dice`
传回 `log`

`val()`

进入模型 `eval` 模式
在验证集上，遍历验证集
 拆分成 `data`(分割前肝脏图片)和 `target`(分割后肝脏图片)
 将模型的参数梯度初始化为 0
 将 `data` 输入模型，得到 `output`
 计算损失函数
 更新 `loss`
 更新 `dice`
 传回 `log`

6. 保存当前状态
7. 更新模型历史最好状态
8. 深监督系数衰减
9. Early-Stop 判断。

流程图如下图所示:




图 2-12 本地训练流程图

2.4.3 基于 TLS1.3 改良的 trojan 模型参数传输

Trojan 是目前比较新的一种协议，Trojan 的设计理念与传统协议的设计理念相反，Trojan 不使用强加密和随机模糊，而是直接模仿互联网最常见的协议 HTTPS，以此来达到设计的目的。HTTPS 协议本身就含有加密，而且 TLS 1.3 更是强加密，现今无法通过简单方式破解。Trojan 本身使用了 HTTPS 的特性，自带了加密和混淆的属性。与 Shadowsocks 相反，Trojan 不使用自定义的加密协议来隐藏自身。相反，使用特征明显的 TLS 协议(TLS/SSL)，使得流量看起来与正常的 HTTPS 网站相同。TLS 是一个成熟的加密体系，HTTPS 即使用 TLS 承载 HTTP 流量。使用**正确配置**的加密 TLS 隧道，可以保证传输的保密性（拦截方无法得知传输的内容）、完整性（拦截方一旦试图篡改传输的密文，通信双方都会发现）、不可抵赖（拦截方无法伪造身份冒充其他参与方）以及前向安全（即使密钥泄露，拦截方也无法解密先前的加密流量）。

对于被动检测,Trojan 协议的流量与 HTTPS 流量的特征和行为完全一致。而 HTTPS 流量占据了目前互联网流量的一半以上,且 TLS 握手成功后流量均为密文,几乎不存在可行方法从其中分辨出 Trojan 协议流量。

对于主动检测,当防火墙主动连接 Trojan 服务器进行检测时,Trojan 可以正确识别非 Trojan 协议的流量。与 Shadowsocks 等代理不同的是,此时 Trojan 不会断开连接,而是将这个连接代理到一个正常的 Web 服务器。在拦截方看来,该服务器的行为和一个普通的 HTTPS 网站行为完全相同,无法判断是否是一个 Trojan 代理节点。

但是,目前世界上主流的 TLS1.2 协议存在着兼容、安全与性能等方面的缺陷,我们采用 TLS1.3 协议代替传统的 TLS1.2 协议。在安全方面,TLS1.3 做了一些改进:

1. 伪随机数函数由 PRF 升级为 HKDF (HMAC-based Extract-and-Expand Key Derivation Function);
2. 明确禁止在记录协议里使用压缩,因为使用压缩被是存在漏洞的并且有可能被黑客用特殊算法破解;
3. 废除了 RC4、DES 对称加密算法;
4. 废除了 ECB、CBC 等传统分组模式;
5. 废除了 MD5、SHA1、SHA-224 摘要算法;
6. 废除了 RSA、DH 密钥交换算法和许多命名曲线;
7. ServerHello 之后的所有握手消息采取了加密操作,可见明文大大减少;

DSA 证书不再允许在 TLS 1.3 中使用

此外,性能提升是 TLS1.3 的一个关键部分,因为随着 HTTP/2 的性能全面提升和 HTTP/3 的进一步发展,加密传输的效率也成为了 TLS 发展的重要瓶颈也是 HTTPS 连接的瓶颈,TLS1.3 利用扩展字段 extension 做了很多细节改善。下面是 TLS1.3 的握手流程:



图 2-13 TLS1.3 三次握手

+表示该报文中值得注意的 extension

* 表示该内容也可能不被发送

{ } 表示该内容使用 handshake_key 加密

[] 表示该内容使用 application_key 加密

TLS1.3 协议采用 AEAD 算法进行加密解密,使用 AEAD 加密机制和协商出来的加密算法对消息报文进行加密:

$AEAD_{Encrypted} = AEAD_Encrypt(write_key, nonce, plaintext)$

TLS1.3 中 AEAD 算法将单个密钥,随机数,明文作为输入附加参数,下面是有关 AEAD 加密的流程图:




图 2-15 AEAD 加密算法

我们将使用优化后的 trojan 协议来传递我们的模型参数，保障模型训练过程的安全性。

2.4.4 基于 AllReduce 的分布式计算的 FedAvg 聚合

在参与方本地训练完成之后并传输过后，便需要将各个参与方的参数进行聚合得到最终的模型参数。将用户本地训练参数进行整合时，我们采用**基于 AllReduce 算法的分布式计算的 FedAvg 算法**来实现。同时使用该算法可以进一步保护每个用户的本地数据隐私。

传统的深度学习方法假设数据是独立同分布（Independent Identically Distribution, IID）的。在使用深度学习方法进行医学影像辅助疾病诊断中，开发者不得不假设样本数据是独立同分布。然而，一些病变结构在图像中的空间位置相近，不同的病变结构会因为具有相似的特征而被指向同一潜在生理区域。如果我们简单地将所有数据是为 IID 数据，那么利用机器学习进行医学影像辅助疾病诊断时就会导致疾病潜在结构原因的统计特性发生系统性改变，即使提供大量的训练样本也无法减少偏差带来的问题。而在联邦学习的应用场景中，每个用户的数据都是独立产生的，不同的用户数据的非同源数据具有不同的分布特征，而在每一个用户设备进行本地学习时，所学习的数据是非独立同分布的(Non-IID)。因此我们可以很好的解决进行医学影像辅助诊断时存在的误诊问题。

FedAvg 方法在保护用户本地数据隐私上有很大的优越性。它允许多个用户同时训练一个模型。用户不需要在训练过程中传递样本具体信息而只用传递本地训练模型参数。在我们的模型中，本地用户负责训练本地数据得到本地模型并将模型权重与其

他在线用户协商整合，经过多轮迭代后最终得到一个趋近于集中式机器学习结果的模型，在这个过程中我们只涉及到模型权重的传递避免了样本数据的传递，能够有效降低传统机器学习源数据聚合带来的许多隐私风险。Fedavg 的收敛性也是得到过证明的。目前已有的论文《On the Convergence of FedAvg on Non-IID Data》从理论上证明了 FedAvg 在处理 Non-IID 数据时的收敛性问题，证明在 FedAvg 算法的有效性。此外，考虑到各个参与方的数据量不同，FedAvg 所采用的是加权平均的方法，即并不将所有参与方看作同等地位，这样有效解决了参与方数据量不同的问题，使得聚合结果能更好地代表全局属性。

同时，传统的联邦学习需要依赖中央服务器进行聚合。这就导致了中央服务器可能被攻击者操控而产生错误的模型。为了解决服务器不完全可信的问题，在将用户本地训练参数进行整合时，我们通过基于 AllReduce 算法的分布式计算的 FedAvg 算法来实现。




图 2-16 传统联邦学习依赖于中央服务器

AllReduce 是一种将所有参与用户的目标数组减少到单个数组的操作，并将结果返回到所有的进程中。在操作中，我们把每个用户抽象为整个训练过程中的一个计算单元，通过引入高性能计算领域中的 Ring-AllReduce 算法，减少发送数据花费的时间，而把时间更多用在处理有用工作上。Ring-AllReduce 可以让我们在多设备和多节点的情况下，更加有效地平均梯度。在训练中使用这个带宽优化的算法，可以显著减少通信开销，并由此扩展到更多的设备上，同时仍然保留同步随机梯度下降的确定性和可预测的收敛性。其中，最常用的为 Ring-AllReduce 算法。Ring-AllReduce 算法如

下所示：

第一阶段，将 N 个参与者连在一个环上，之后每个参与者把自己的数据分成 N 个子数组。




图 2-17 第一阶段初始情况

对于第 p 位参与者，他需要将自己的第 p 个子数组发送给下一位参与者(第 $p+1$ 位参与者)，同时从前一位参与者(第 $p-1$ 位参与者)获得一个子数组。




图 2-18 第一阶段交换子数组

之后，第 p 个参与者将自己的第 $p-1$ 个子数组和从上一位参与者(第 $p-1$ 位参与者)处获得的子数组通过 AllReduce 的运算符聚合在一起，并将其发送给下一个参与者(第 $p+1$ 个参与者)。




图 2-19 第二阶段交换聚合子数组

以此循环 N 次之后，每一位参与者都会包含最终聚合结果的一份。




图 2-20 AllReduce 最终结果

2.4.5 模型效果评价指标确立

在完成模型参数聚合之后，我们需要对全局模型进行测试以判断模型的性能。在本部分，我们选择使用 **Dice 系数** 作为指标，评估使用训练后的模型对测试集数据进行图像分割得到的预测结果以及真实情况之间的相似度。显然，若两者之间的相似度越高说明预测结果越贴近现实，模型的预测精确度越高；反之，若两者之间的相似度越低说明预测结果与真实情况的偏差越大，模型的预测精确度越低。

为了便于计算 **Dice 系数**，我们需要对图像数据进行处理，转化为独热编码（One-Hot Encoding）。独热编码又称为一位有效编码，主要是采用 N 位状态寄存器来对 N 个状态进行编码，每个状态都由他独立的寄存器位，并且在任意时候只有一位有效，即，只有一位是 1，其余都是零值。独热编码是分类变量作为二进制向量的表示。这首先要求将分类值映射到整数值。然后，每个整数值被表示为二进制向量，除了整数的索引标记为 1 之外，其它都是零值，如下图所示：




图 2-21 独热编码

例如表 XX 中共有 4 个样本，每个样本都有三个特征：

表 2-1 独热编码实例样本

	特征 1	特征 2	特征 3
样本 1	1	1	1
样本 2	2	2	2
样本 3	1	3	3
样本 4	2	4	1

其中特征 1 有 1、2 两种取值，特征 2 有 1、2、3、4 四种取值，特征 3 有 1、2、3 三种取值。独热编码就是保证每个样本中的单个特征只有 1 位处于状态 1，其他的都是 0，这些样本的独热编码如表 XX 所示。

表 2-2 实例样本转化为独热编码

	特征 1	特征 2	特征 3
样本 1	01	0001	001
样本 2	10	0010	010
样本 3	01	0100	100
样本 4	10	1000	001

那么样本 1 就可以用[0,1,0,0,0,1,0,0,1]表示，样本 2 就可以用[1,0,0,0,1,0,0,1,0]表示，样本 3 和样本 4 同理。为此我们定义了 `to_one_hot_3d` 函数将数据从 `tensor` 类型转化成独热编码，主要使用 `pytorch` 的 `zeros()`方法和 `scatter_()`方法，将多维的数据展开成一维并在相应的特征位置 1。`to_one_hot_3d` 函数的定义如图所示。

Dice 相似性系数（Dice Coefficient, DC）是常见的语义分割评价标准，也可以作

为损失函数衡量分割结果和标签之间的差距。Dice 系数是一种取值范围在[0,1]的集合相似度度量函数，反映了预测结果和真实情况之间的交集对并集的比例，被定义为：

$$DC = \frac{2|P \cap T|}{|P| + |T|}$$

其中，P 表示预测结果（Predictions），T 表示真实情况（Ground Truth）， $|P \cap T|$ 是 P

和 T 之间的交集， $|P|$ 和 $|T|$ 分别表示 P 和 T 的元素个数，分子的系数为 2，是因为分母存在重复计算 $|P|$ 和 $|T|$ 之间的共同元素。由于在测试时所用到的测试数据分为多组，在计算 Dice 系数时依据分组，首先计算当前分组的 Dice 系数，然后根据已经求出的各组的 Dice 系数计算算术平均值。最终得到的平均 Dice 系数用于衡量模型的性能。为了实现 Dice 系数的计算，我们在 metrics.py 中定义了 DiceAverage 类，并在这个类中定义了数个方法进行计算。该类在实现上述公式的同时，每计算一个 Dice 系数都会更新 Dice 的平均值。

2.4.6 模型效果全局测试

在上面的指标确立后，我们构建模型测试主函数，主函数主要由两个部分组成，分为**测试配置部分**和**具体测试部分**。具体运行时，在进入主函数开始执行后，首先进行测试配置部分的相关配置，包括引入参数、确定测试结果的保存路径、加载模型、为模型分配设备（cpu 或者 cuda）、设置日志路径、加载数据集等等。完成测试的配置之后，脚本将开始进行测试，所有测试集中的输入数据将以图像为单位被传入模型得到预测结果；接着根据预测结果和数据集的标签（即图像分割的真实情况）进行 Dice 系数的计算；计算得到的 Dice 系数将写入日志，模型输出的预测结果将生成图像文件并被保存在测试结果中。模型测试主函数的流程图如图所示。




图 2-22 全局模型测试思路图

模型测试主函数实现的测试过程如下：

1. 加载 `config.py` 中的参数
2. 加载测试结果保存路径 `save_path`
3. 选择设备 `torch.device()`
4. 载入模型
5. 调用 `Test_Logger` 类初始化测试日志
6. 调用 `Test_Datasets` 类读入数据
7. 将每一张图像输入 `predict_one_img` 函数，得到预测分割结果和 Dice 系数；更新日志写入图像的 Dice 系数；使用 `SimpleITK` 的 `WriteImage` 方法输出预测结果图像。
8. 如果仍有未处理的图像，回到 7 继续处理。

其中，`predict_one_img` 函数的主要功能为利用模型将输入的图像进行分割得到预测的图像分割结果，再将预测结果与输入图像对应的标签，即预期分割结果进行比较，计算 Dice 系数。`predict_one_img` 函数的输入参数为模型、测试模型的数据以及运行模型的其他参数，输出为 Dice 系数和模型输出的分割结果。其大致分为三个部分：初始化、模型运算、Dice 系数计算。`predict_one_img` 函数的流程图如图 2-23 所示。需要指出的是，在将数据输入模型进行运算时，数据是分批输入的，一次该部分的主体是一个 `for` 循环结构。在全部的模型运算完成后，要将输出结果整合并且

转化为独热编码，然后才能计算 Dice 系数。predict_one_img 函数实现的图像处理过程如下：

1. 初始化

- (1) 使用 torch.utils.data 库中的 DataLoader() 载入数据
- (2) 模型选择以评估模式进行运算 (model.eval())
- (3) 初始化一个用于更新 Dice 系数值的 DiceAverage 类的对象
- (4) 使用 to_one_hot_3d() 将预期分割结果 (数据标签) 转化为独热编码 target

2. 模型运算 (不计算梯度)

- (1) data.to() 逐步输入数据
- (2) model(data) 输出结果
- (3) 将结果更新到数据集
- (4) 还有未输入的数据则回到 2.1

3. Dice 计算

- (1) 使用 to_one_hot_3d() 将模型输出的结果转化为独热编码 pred_img
- (2) 将数据标签和模型输出的独热编码 target 和 pred_img 传递给 DiceAverage 类的 update 方法计算 Dice 系数

4. 函数返回模型输出的预测结果图像和 Dice 系数




图 2-23 Predict_one_img 函数流程图

2.4.7 DICOM 与 nii 图像格式转换

目前，PACS 系统中最常用的医学影像标准为 DICOM 标准，它提供了 DICOM 的相关接口。DICOM (Digital Imaging and Communications in Medicine)：DICOM 是医学影像领域的国际标准，定义了医学图像和相关信息的传输和存储格式。大多数 PACS 系统支持 DICOM 接口，我们可以使用 DICOM 标准进行图像的获取、传输和

存储。通过 DICOM 接口，我们可以发送图像数据到 PACS 系统，并获取 PACS 系统中的图像数据进行处理和分析。

但是，由于 nii 格式的影像文件简单移动，AI 科学家们更倾向于使用 nii 格式的图像文件完成医学图像分割模型的开发，因此我们必须设计一款能够将 DICOM 图像文件与 nii 格式的图像文件相互转换的工具并集成到我们系统当中，才能完成系统到 PACS 的接入。我们选择由 rordenlab 开发的 dcm2niix 作为底层，它能实现单张 DICOM 与 nii 文件的相互转化，但是我们要对其增加隐私保护以及批量处理的功能。下面如何使用 python 进行批处理：

1. 首先遍历一个含有非常多个 dicom 序列的文件夹，然后将其的 dicom 文件的路径保存到一个 txt 文件中，然后读取 txt 中的文件路径，在 for 循环中调用 dcm2niix 进行格式的批处理。部分代码如下：

```
#coding=utf-8
import SimpleITK as sitk

def dcm2nii(dcms_path, nii_path):
    # 1.构建dicom序列文件阅读器，并执行（即将dicom序列文件“打包整合”）
    reader = sitk.ImageSeriesReader()
    dicom_names = reader.GetGDCMSeriesFileNames(dcms_path)
    reader.SetFileNames(dicom_names)
    image2 = reader.Execute()
    # 2.将整合后的数据转为array，并获取dicom文件基本信息
    image_array = sitk.GetArrayFromImage(image2) # z, y, x
    origin = image2.GetOrigin() # x, y, z
    spacing = image2.GetSpacing() # x, y, z
    direction = image2.GetDirection() # x, y, z
    # 3.将array转为img，并保存为.nii.gz
    image3 = sitk.GetImageFromArray(image_array)
    image3.SetSpacing(spacing)
    image3.SetDirection(direction)
    image3.SetOrigin(origin)
    sitk.WriteImage(image3, nii_path)

def dcm2nii_ui():
    src_path=input('please input dcm file path')
    save_path=input('please input nii.gz save path')
    dcm2nii(src_path, save_path)
```

图 2-24 读取文件夹

2. 然后，读取 txt 文件，进行批处理转换，这里为了保护病人隐私，去掉了原文件的

信息，使用以随机产生的名字。部分代码如下：

```
# 以切片的轴向作为保存png的子文件夹名
foldername = axis
png_save_path = os.path.join(img_save_path, f, foldername)
if not os.path.exists(png_save_path):
    os.mkdir(png_save_path)

flag = 100
if axis == 'x':
    (axis, y, z) = nii.shape
    flag = 0
elif axis == 'y':
    (x, axis, z) = nii.shape
    flag = 1
elif axis == 'z':
    (x, y, axis) = nii.shape
    flag = 2
else:
    print("wrong axis")

for i in range(axis):
    if flag == 0:
        slice = nii_fdata[i, :, :]
    elif flag == 1:
        slice = nii_fdata[:, i, :]
    elif flag == 2:
        slice = nii_fdata[:, :, i]
```

图 2-24 批量图像转换


最后，处理好的文件，可以到输出目录中去查找。

2.4.8 医学影像和文本数据管理系统的开发

我们所有图像均以 DICOM 格式存储，为了便于医学研究人员和临床专业人员有效地组织、检索和分析医学图像和相关数据，我们开发了一个**医学影像和文本数据管理系统**，该系统拥有强大的存储，索引和查询功能。该系统基于 DICOM3.0 协议进行数据传输；支持基于 TCP/IP 的通信协议；底层使用 NIO 实现，支持基于 HTTP 通信协议。

该系统使用 Java 作为主要的编程语言，具有广泛的应用和良好的跨平台性能。在全文索引和检索功能方面，使用 Apache Lucene 来进行全文索引和检索功能，其中

Lucene 是一个功能强大的开源搜索引擎库，提供了高性能、可扩展的全文搜索和索引功能。使用 MongoDB 用于存储原始图像和文本数据的数据库部分。此外，为了能与外部系统进行通信和交互，我们还开发了提供了基于 REST（Representational State Transfer）架构的 API 接口，使客户端能够与系统进行通信和交互。



2.4.9 可视化用户界面以及作品部署

除了模型训练，还需要前后端的开发、数据库、网络和通信技术、安全技术以及部署与运维工具来搭建起整个作品。

整个系统运行在 B/S 架构上。B/S（Browser/Server, 浏览器/服务器）架构是 Web 兴起后的一种网络结构模式。Web 浏览器是客户端最主要的应用软件。这种模式统一了客户端，将系统功能实现的核心部分集中到服务器上，简化了系统的开发、维护和使用；客户机上只需要安装一个浏览器，服务器上安装 SQL Server, Oracle, MySQL 等数据库；浏览器通过 Web Server 同数据库进行数据交互。基于此，用户端无需再额外安装专门的客户端，而只需要使用 Web 浏览器即可。

在服务器端，每个参与方在本地均有私有的数据库以及服务器用来存放本地的医学影像数据、完成本地的模型训练以及提供图像分割服务等。我们的作品可以接入目前广泛使用的医疗 PACS 系统中融入当前医疗体系，我们将参与方上传的图像数据通

过 PACS 系统存入服务器中，并允许系统在模型训练以及图像分割时从存储服务器获得图像数据完成任务。此外，在完成分割任务后，分割完成的图像将存入临时存储数据库中，在经过医生手动校验之后，分割完成的图像与之前图像会一起投入到新一轮的模型训练当中。

具体的讲，我们租用了三台华为云耀服务器（2 核 4G）用来存放本地影像数据以及提供服务等，选择 Ubuntu20.04 作为操作系统并采用开源 Web 服务器 Apache HTTP Server 作为 web 服务器软件。之后，我们还需要完成网络的配置以及防火墙的搭建，对于防火墙的搭建，我们遵循如下规则：

- 1 允许必要的入站和出站连接，如 HTTP（端口 80）或 HTTPS（端口 443）。
- 2 禁止不必要的入站连接，如 SSH（端口 22）或其他管理端口。
- 3 限制特定 IP 地址或 IP 范围的访问，以允许仅特定来源的连接。
- 4 配置入侵检测和阻止系统（IDS/IPS）以监测和阻止潜在的攻击行为。
- 5 配置网络地址转换（NAT）以隐藏服务器的真实 IP 地址。

此外，我们还需要完成 Web 应用程序的部署、Web 服务器的配置以及测试与调试等。前端方面，我们采用 HTML/CSS 构建应用的网页结构和样式，JavaScript 实现网页的交互逻辑和动态效果并且将 React.js 作为前端框架提供更高效率的组件化和开发模式。后端方面，我们使用 Go 语言作为后端开发语言，并利用 GO 标准库中包含的用于处理 HTTP 请求和构建 Web 应用的包进行 Web 开发。数据库选择方面，由于 PACS 系统一般使用关系型数据库（RDBMS）来存储和管理医学影像数据，我们选择 MySQL 来保存分割完成但并未完成校验的图像数据。

在网络和通信数据方面，除了利用 HTTP/HTTPS 完成前端和后端之间的安全数据传输外，我们对模型聚合时的传输协议做了特定优化，我们使用优化后的 trojan 对模型参数进行传输。

在用户认证与授权方面，我们使用加盐的哈希密码 SHA3-256 完成密码的存储与验证，下面是使用加盐的 SHA3-256 完成密码的存储和验证的步骤：

密码存储：

- 1.注册用户时，生成一个随机的盐值（salt），通常是一个固定长度的随机字符串。
- 2.将用户提供的密码与盐值进行组合，形成密码+盐值的字符串。
- 3.对密码+盐值的字符串进行 SHA3-256 哈希运算，得到哈希值。

4.将盐值和哈希值存储在数据库中，与用户相关联。

密码验证：

1.用户登录时，系统从数据库中获取该用户的盐值和哈希值。

2.将用户提供的密码与获取到的盐值进行组合，形成密码+盐值的字符串。

3.对密码+盐值的字符串进行 SHA3-256 哈希运算，得到哈希值。

4.将得到的哈希值与数据库中存储的哈希值进行比对。如果两者匹配，则密码验证通过，用户身份得到确认。



图 2-25 SHA3-256 的密码存储与验证

此外,对于用户的权限分配,作品采用 RBAC 模式。RBAC 是 Role-Based Access Control（基于角色的访问控制）的缩写，是一种用于授权和访问控制的安全模型。RBAC 通过将权限分配给角色，再将角色授权给用户，实现对系统资源的访问控制和权限管理。

至此，作品所有功能全部完成。

第三章 作品测试与分析

本节将分步介绍作品测试的方案、环境、设备、数据、步骤以及测试结果分析。测试步骤大致分为：数据预处理、图像分割（模型输出）、模型比较。本节旨在说明作品在使用联邦学习框架的情况下所得到的模型在图像分割时性能优于集中式学习框架训练的模型性能。

3.1 测试方案

测试主要分为**模型性能测试**、**系统功能测试**两个部分

其中模型性能测试部分，首先进行数据预处理，预处理后的数据将分别用于训练联邦学习框架模型和集中式学习框架模型，然后使用相同的测试集对两个模型进行测试，分别计算 loss 和 Dice系数衡量模型性能，通过对比进行结果分析。由于设备数量有限，联邦学习框架的应用以模拟的方式在同一台设备上进行。考虑到图像分割的参数数量通常较大，同时正常场景下，一般医院参与联邦学习训练图像分割任务的数量也并不多，我们将参与联邦学习训练的客户端数量设置为 4 个客户端参与，batch size 为 4。我们划分 4 个进程模拟联邦学习中的 4 个客户端，其中训练集中的数据模拟分布式划分为四组，通过共享参数进行联邦平均模型参数达到运行联邦学习的效果。验证集用相同的数据（即 4 个 nii 格式 CT 影像文件），便于验证测试效果。测试时训练的学习率为 0.0001。在数据集划分时，训练集为 16 个 nii 格式 CT 影像文件，验证集为 4 个 nii 格式CT 影像文件，测试集为 2 个 nii 格式 CT 影像文件。模型训练总计为 114 个 epoch。。

对于系统功能测试部分，我们将分割好的数据集2传入系统当中，并由医生手动确认或调整分割。再将正确分割的数据集2与数据集1一起用于下一轮的模型训练当中。此外，我们随机登录了一些患者、医生与管理者的账号并检查权限分配以及对应的功能是否出现问题。我们还使用各种防火墙来拦截捕获trojan协议包并尝试对其尝试进行解密。

3.2 测试环境的搭建

对于模型性能部分，作品在 64 位 Ubuntu 操作系统环境下进行测试，配置如下表所示。

表3-1 测试环境的操作系统配置

配置名	配置
操作系统	Linux Ubuntu
内核版本	5.4.0-97-generic
发行版本	Ubuntu 20.04

作品代码使用 python 编写，测试时在 python3.8.13 环境下进行，测试所使用的部分python 库及其版本如下表所示：

表 3-2 测试环境的 python 库配置

Python 库名称	版本
pytorch	1.11.0
torchvision	0.12.0
SimpleITK	2.1.1.2
scipy	1.6.2
matplotlib	3.3.4
pandas	1.2.4
tensorboardX	2.5

由于配置较多，不能一一列出，所有配置均保存在env.yaml文件中，可以直接查看。

对于作品功能测试部分，我们在windows11系统下进行测试，访问浏览器为Microsoft Edge。

3.3 测试设备

模型性能的测试部分主要在服务器上运行，服务器具体参数如下表所示：

表 3-3 测试设备配置

配置名	配置
制造商	LENOVO
型号	30BDS5YY00
版本	ThinkStation P920
序列号	PC1JRQQ2
SKU 码	LENOVO_MT_30BD_BU_Think_FM_ThinkStation P920
CPU 型号	32 Intel(R) Xeon(R) Gold 6234 CPU @ 3.30GHz
物理 CPU 个数	2
逻辑 CPU 个数	32
GPU 型号	NVIDIA Quadro RTX 5000
GPU 个数	2

此外，对于系统功能测试以及系统安全性测试这两个部分，我们使用笔记本电脑就可以完成。

3.4 测试数据

3.4.1 分割模型性能测试

对于训练以及测试模型的数据，我们在作品设计与实现部分说明要对其进行预处理。本项目所使用的数据集的图像文件为 nii 格式，使用 ITK-SNAP 软件可以查看图像的基本信息，以及大致的图像情况，原始的 LiTS17 图像如图 3-1 和图 3-3 所示。原始的 LiTS17 数据将作为图像预处理的输入，经过 preprocess_LiTS.py 的处理之后，输出如下图所示。从图中的 Image Summary 中对图像基本属性的描述可以看到，预处理的过程调整了图像的维度、体素间距、数据类型（浮点型转化为短整型），图像的大小被压缩。从三视图的角度来看，俯视图的形状由圆形改为了方形，正视图和侧视图被缩小、集中于肝脏的部位，剔除了与肝脏肿瘤分割无关的部分。同时，预处理前后的图像在灰度上有着明显的差别，对于灰度值在阈值之外的图像，其灰度值被截断为阈值。预处理前后对比如下所示：



图3-1 图像预处理输入1




图3-2 图像预处理输出1



图3-3 图像预处理输入2




图3-4 图像预处理输出2

图像经过预处理后，将首先被随机的加入起到隐私保护作用的噪声，然后被输入模型进行图像分割，分割得到的结果依旧以 `nii` 为文件拓展名，可以使用 ITK-SNAP 软件将其附加到输入的图像上，查看图像分割结果。部分分割后图像如下图所示：




图3-5 模型直接输出图像1




图3-6 模型直接输出图像2

将这两个模型输出的图像附加到输入的图像上后得到的分割结果如图所示，其中红色部分即模型输出图像：




图3-7 最终分割结果1




图3-8 最终分割结果2

在 LiTS 数据集中，同样包括了标准的分割结果，即用于监督学习的标签，标签也可以附加到原始数据上，下图展示了与前文图像分割结果对应的标签，可以直观地与

上图进行对比：




图 3-9 正确分割图像 1




图 3-10 正确分割图像 2

通过图像分割结果与数据标签的对比，可以看出我们的作品的图像分割效果在直观上是良好的。为了更加量化地衡量模型的性能，我们在每个 epoch 之后计算了损

失函数值 (loss) 和 Dice 系数以考察模型的收敛速度以及图像分割的效果，如图所示：




图 3-11 loss 和 Dice 系数折线图

图中 train_dice 和 train_loss 分别表示模型训练时的 Dice 系数和 loss 值，val_dice 和 val_loss 分别表示模型验证时的 Dice 系数和 loss 值。从图中可以看出，在经过大约 20 个 epoch 之后，模型基本收敛，收敛速度较快。收敛后的 Dice 系数基本在 0.8-0.9 之间，模型有着不错的预测相似度。另外，训练过程和验证过程的 loss 和 Dice 差距较小，说明并不存在过拟合的情况。

3.4.2 与集中式机器学习的模型比较

在本小节中，我们将对联邦学习框架训练的模型性能和集中式学习框架训练的模型性能进行比较。展示我们的作品如何在提升安全性的同时保证了性能。与上一小节一样，我们同样通过 loss 和 Dice 衡量模型的性能，如图所示。




图 3-12 联邦学习模型和集中式学习模型的 loss 和 Dice 系数折线图

图中 dist_dice 和 dist_loss 分别表示使用联邦学习框架训练模型的 Dice 系数和 loss 值，nor_dice 和 nor_loss 分别表示使用集中式学习框架训练模型的 Dice 系数和 loss 值。从图中可以看出，两种学习框架下 loss 的下降速度差距较小，联邦学习在大约 20 个 epoch 后收敛，相较之下，集中式学习的 loss 的波动始终比较大。从 Dice 系数的角度来看，收敛后联邦学习的 Dice 略高于 0.8，明显优于波动幅度非常大的集中式学习。

遗憾的是，由于数据集以及算力资源的原因，我们很难开展大规模的训练以及测试，只能通过小规模测试进行可行性验证。

3.4.3 系统功能测试

首先我们对图形转换工具进行测试，将图片输入进工具进行格式的转换，并打开查看具体信息：




图3-13 图像格式转换效果

模型参数的传输方面，我们用多种防火墙进行拦截trojan协议包，但并未成功，说明具有较强的抗拦截能力。

3.5 结果分析

通过上面的测试，我们可以得出如下结论：

在模型方面

- 1、联邦学习框架的收敛速度与集中式学习框架相当。
- 2、联邦学习框架的分割结果略优于集中式学习框架。
- 3、联邦学习框架可以结合差分隐私，提供更好的隐私保护。
- 4、集中式学习框架结合差分隐私后收敛情况不理想。
- 5、联邦学习框架相较于集中式学习在数据和模型信息加入噪声之后具有更强的鲁棒性

在系统功能方面

1. 本系统能实现将DICOM格式影像文件与nii格式文件相互转换，能够利用PACS系统提供的接口嵌入到PACS系统的，深度融合当前医疗体系。

2. 本系统具有严格的权限分配机制，为不同用户分配对应的权力。
3. 系统具有全流程的安全性保护机制。
4. 参与方完全具有决策权，能自行决定是否参与下一次的聚合训练。
5. 系统具有正向进化性，随着系统数据量的增多，分割效果会有提升。

由此，我们可以认为，采用去中心化的联邦学习框架，基于PACS的系统开发以及管理能比较好的解决当前医学影像AI产品的痛点，在保证医学影像分割效果优良的前提下实现对患者隐私的更好保护并且能够比较好的融入当前医疗的流程。

第四章 创新性说明

4.1.去中心化的联邦学习框架分割图像

考虑到传统集中式机器学习需要将所有数据集中在一起训练所带来的隐私安全问题，医院等影像数据掌握方并不愿意将数据交给产品开发方进行训练，开发者不能获得足够多的数据训练出好的模型。这个问题进一步造成了当前医学影像 AI 产品的性能较差、融入当前医疗体系能力差以及实际可用产品较少等问题。

本作品采用联邦学习框架完成医学影像分割的任务。在全工作流程中，医院不需要将自身掌握的图像数据上传，只需要在本地完成训练任务并与其他参与方聚合即可，这大大减少了医院数据泄露的风险，使医院隐私安全自主可控。此外，针对一般联邦学习的中央服务器不可信的问题，我们开发了**基于 AllReduce 算法的去中心化联邦学习框架**，使得联邦学习的模型聚合不再依赖于中央服务器，提高了模型聚合的安全性。

在模型训练以及图像预处理过程中，我们均采用了高斯加噪的差分隐私方法，这样即使模型梯度发生了泄露，攻击者也很难恢复出原来图像的信息。

4.2 基于 TLS1.3 的改良 trojan 安全传输

传统的联邦学习中一般用 TCP 协议进行参数传输，虽然它提供了数据包的可靠传递、流量控制、拥塞控制和错误检测等功能，但 TCP 本身并不提供数据的加密和隐私保护。如果不在传输模型参数的过程中增加保护数据的隐私和安全性的措施，则很容易造成模型参数泄露的问题，并由此带来原始数据泄露等一系列安全问题。

针对这个问题，我们采用 **trojan 传输协议来保障传输的安全性**。Trojan 协议最大的特性在于它有很强的抗检测能力。无论是主动检测还是被动检测，trojan 协议均能够伪造成 https 等没有掠夺价值的流量通过检测。此外，就目前来看，如果要识别并阻断 trojan 连接就只能使用无差别封锁或者大规模中间人攻击等成本较高的方法。

同时，传统的 trojan 采用 TLS1.2 协议，但目前研究表明 TLS1.2 仍然存在着很多漏洞。我们对用最新的 TLS1.3 来替代 trojan 中的 TLS1.2 部分，使用了复杂的密钥导出过程，增强了最终使用密钥的安全性。同时简化了所使用的加密算法，大大精简了协

议。

4.3 基于 PACS 的可视化系统打造

医疗影像 PACS 系统是目前最流行的医疗信息系统，用于存储、检索、传输和显示医疗影像。它可以集成多种医疗设备，如 X 光机、CT、MRI、超声等，将这些设备产生的数字影像转换成标准格式，进行存储和管理，以便医生和专业技术人员进行诊断和治疗。目前，PACS 系统已经被各大医院广泛使用，并纳入其医疗体系中。要降低医院使用产品的成本，更好的融入当前医疗流程，必须得从嵌入 PACS 系统出发。

由于 PACS 系统存储的是 DICOM 格式的图像，而 AI 领域用于模型训练以及分割的图像大多数为 nii 格式，因此必须开发一个能批量进行图像格式转换的工具。我们采用 dcm2nii 开源工具作为底层，增加批处理以及隐私保护功能作为本系统与 PACS 系统的接口工具。

此外，我们并不使用 PACS 系统原本的服务器提供服务以及完成未验证图像的存储，因为那样会破坏 PACS 原有的存储结构。我们将分割好的图像独立存放于独立的服务器中，并增加验证与未验证的标签用以区分是否正确分割。只有经过验证的图像才能被用于下一轮模型训练中。

同时，考虑到 PACS 综合功能较为复杂，我们对用户权限进行了严格的分配，并采用加盐的 SHA3-256 完成密码的存储以及验证。

4.4 低成本、强安全性以及高使用价值

本作品从选题到设计再到开发都解决当前产学领域存在的痛点出发。当前医学人工智能领域的学者已经能够完成不同人体部位的高精度图像分割，但医院等医疗主体却发现它们很少能获得易于使用的合格产品。这其中的问题一方面有开发部署成本问题，另一方面也有出于隐私保护的需要医院并不能让技术人员大量获得影像数据。

本作品采用联邦学习框架，使得模型不需要将全部数据集中在一起就能获得全部数据的特征。这个方法不仅降低了数据集的获取成本，更在一定程度上缓解了医院等对其数据隐私的担忧。得益于针对联邦学习的优化算法的发展，我们模型的分割效果得到了保证。此外，为了进一步保证模型的安全性，我们采用了去中心化的联邦学习框架，抛弃了中央服务器，使得每个参与者都能完全掌握自身数据（包括模型参数）

而且能从模型聚合中收益。

当然，我们深刻的明白除了打造低成本高安全性的分割模型之外，系统的部署服务的提供也是一个十分重要的环节。为了更好的融入当前医疗体系，降低医院的部署使用成本，我们深入理解了当前广泛使用的 PACS 系统，并决定基于 PACS 系统打造我们的系统，这样不仅可以直接利用 PACS 系统的数据也能够向 PACS 系统中增加数据，使得我们的系统能够真正的融入当前的医疗体系。此外，我们还开发了针对不同用户的网页界面（对应着不同的权限分配），并且在密码存储以及验证方面采用具有高安全的算法。

因此，可以认为我们的作品确实从实际出发解决了当前该领域的痛点，其低成本、强安全性以及高使用价值可以成为医院选择该系统的理由。

第五章 总结

5.1 已经完成的工作

本作品创新性的开发了一个具有显著特色和亮点的人工智能医学影像分割系统。通过人工智能对医学影像进行分割可以帮助医师判读医学影像，提高医学影像分析的效率，并嵌入医疗领域常用的系统进行开发，减轻医师负担，节约医疗资源，具有广阔的应用前景和市场前景。

考虑到传统的集中式机器学习需要将所有数据集中到一台主机上对模型进行训练，而医学影像包含大量患者的个人敏感信息，不便共享，小规模医疗机构也难以掌握数量足以训练模型的医学影像，本作品采用联邦学习框架，以分享梯度信息的方式，实现在不同医疗机构之间模型训练过程中的数据共享。攻击者通过梯度信息获得患者个人隐私数据虽然比较困难，但是仍然有现有的攻击手段可以实现。因此，在使用联邦学习框架的基础上，本作品还应用了差分隐私技术，通过对进行训练的医学影像和模型梯度等信息添加随机噪声的方式，进一步保护患者个人隐私信息。攻击者将难以判断获得的隐私信息是真实的还是随机生成的。

另外，一般的联邦学习框架需要中央服务器进行梯度信息聚合，更新模型，而用户之间并不直接进行梯度信息的共享。一旦中央服务器受到攻击，就可能导致中央服务器拒绝服务或者提供错误的模型，使得整个联邦学习框架瘫痪。为了解决这一问题，本作品采用 AllReduce 聚合算法，以去中心化的方式直接在用户之间共享梯度信息，确保模型服务质量以及安全性。在传输协议方面，我们开发了基于TLS1.3的trojan协议避免被探测拦截以及被解密，保证了模型参数在传输过程的安全性。

在采用差分隐私技术处理医学影像的情况下，本模型的性能优良，收敛速度较快，图像分割结果和数据标签的 Dice 相似度系数在 0.8~0.9 之间，能够有效的帮助医师判读医学影像。与传统集中式机器学习相比，本模型克服了传统的集中式机器学习框架受到差分隐私技术处理医学影像的影响较大，模型难以收敛的问题。

与此同时，我们基于目前医疗领域常用的PACS系统开发我们的系统，打造不同格式图像之间相互转换的工具，使得模型能够直接从PACS系统中获得数据完成训练或者分割任务。同时，我们的系统不依赖于PACS系统的服务器，在独立服务器中的每张图

像都有其对应的状态，通过验证的图像才能被当作下一轮训练的训练集。在web页面方面，用户根据身份不同能看到不同的信息：主治医生能看到其负责的患者图像并有资格对分割好的图像进行验证，系统的管理者不能看到具体的图像但是可以看到全局的状态并决定是否参与下一轮模型训练。

总之，针对目前医学影像 AI 产品领域存在的可用产品少、融入医疗体系难、产品性能不稳定以及隐私保护能力差等问题，本作品通过上述方法降低了数据集的获取成本，保护了患者的隐私安全，解决了医院对隐私问题的担忧，**打造了一款能够融入当前医疗体系、性能稳定且易于使用的产品，具有令人期待的应用场景。**

5.2 存在的不足

由于资源、时间以及知识储备的不足，本作品仍然存在着较多问题：

1. 由于我们不能获得足够多的数据集，初始训练出来的模型的分割精度并不是一个很高的水平。如果能获取到足够多的数据集，初始模型的分割精度可以进一步提高。
2. 在模型的训练过程中，受算力以及数据的限制，我们只模拟了有三个参与方的情况。但在实际的应用中，参与方的数量会有很多，这种参与方数量的增多会给模型分割效果带来什么样的影像这点我们还不确定。
3. 随着对联邦学习研究的进步，SAM 等更加先进的优化模型的方法被提出，我们并没有验证这些最前沿的算法是否在我们的任务上有着更为准确的效果。
4. 服务提供方面，我们的云服务器资源并不充裕，访问时延以及模型分割所需时间均比较长。且我们并不能保证系统在大规模应用时候的稳定性。
5. 受时间限制，系统提供的功能比较有限，只能提供比较基础的功能，一些与之相关的拓展功能并没有设计并加入。
6. 模型传输方面，由于真实的网络状况较为复杂，虽然从理论上来看我们的协议具有优越性，但其在真正场景中应用的性能亟待验证。

5.3 以后的工作

结合目前的进展以及存在的问题，我们认为接下来的工作可以考虑以下几个方面：

1. 模型方面，由于分割精度目前相对而言比较高且随着数据集的增大分割精度还会有进一步的提高，下一步模型优化的重点会放在模型训练的泛化性以及对抗样本攻击等攻击手段的防御性上面。
2. 增加数据量以及参与方数量，采取多种方案模拟参与方用来验证模型在未见领域的健壮性。如果健壮性较差，则采取措施优化。
3. 验证并提高图像转换工具的性能以及稳定性，使之成为一个真正可以大批量完成图像格式转换任务的工具。
4. 增加与核心任务相关的系统功能，进一步提高系统的可用性。
5. 根据不同的网络状况，我们可以选择不同的传输策略，不能仅仅依赖于优化的 trojan。

参考文献

- [1].Gibiansky, Andrew. "Bringing HPC techniques to deep learning.(2017)." URL [http://research. baidu. com/bringing-hpc-techniquesdeep-learning](http://research.baidu.com/bringing-hpc-techniquesdeep-learning) (2017).
- [2].Roth, Holger R., et al. "Federated learning for breast density classification: A real-world implementation."Domain Adaptation and Representation Transfer, and Distributed and Collaborative Learning. Springer, Cham, 2020. 181-191.
- [3].Brisimi, Theodora S., et al. "Federated learning of predictive models from federated electronic health records."International journal of medical informatics112 (2018): 59-67.
- [4].L Raisaro, Francesco Marino, Juan Troncoso-Pastoriza, Raphaelle Beau-Lejdstrom, Riccardo Bellazzi, Robert Murphy, Elmer V Bernstam, Henry Wang, Mauro Bucalo, Yong Chen, Assaf Gottlieb, Arif Harmanci, Miran Kim, Yejin Kim, Jeffrey Klann, Catherine Klersy, Bradley A Malin, Marie Méan, Fabian Prasser, Luigia Scudeller, Ali Torkamani, Julien Vaucher, Mamta Puppala, Stephen T C Wong, Milana Frenkel-Morgenstern, Hua Xu, Baba Maiyaki Musa, Abdulrazaq G Habib, Trevor Cohen, Adam Wilcox, Hamisu M Salihu, Heidi Sofia, Xiaoqian Jiang, J P Hubaux, SCOR: A secure international informatics infrastructure to investigate COVID-19,Journal of the American Medical Informatics Association, Volume 27, Issue 11, November 2020, Pages 1721–1726,
- [5].Xiaoxiao Li, Yufeng Gu, Nicha Dvornek, Lawrence H. Staib, Pamela Ventola, James S. Duncan,Multi-site fMRI analysis using privacy-preserving federated learning and domain adaptation: ABIDE results,Medical Image Analysis, Kaissis, Georgios A., et al. "Secure, privacy-preserving and federated machine learning in medical imaging."Nature Machine Intelligence2.6 (2020): 305-311.
- [6].Xiaoxiao Li, Yufeng Gu, Nicha Dvornek, Lawrence H. Staib, Pamela Ventola, James S. Duncan,Multi-site fMRI analysis using privacy-preserving federated learning and domain adaptation: ABIDE results,Medical Image Analysis,Volume 65,2020,101765,ISSN 1361-8415

- [7].Dong Yang, Ziyue Xu, Wenqi Li, Andriy Myronenko, Holger R. Roth, Stephanie Harmon, Sheng Xu, Baris Turkbey, Evrim Turkbey, Xiaosong Wang, Wentao Zhu, Gianpaolo Carrafiello, Francesca Patella, Maurizio Cariatì, Hirofumi Obinata, Hitoshi Mori, Kaku Tamura, Peng An, Bradford J. Wood, Daguang Xu, Federated semi-supervised learning for COVID region segmentation in chest CT using multi-national data from China, Italy, Japan, Medical Image Analysis, Volume 70, 2021, 101992, ISSN 1361-8415,
- [8].Lu, Ming Y., et al. "Federated learning for computational pathology on gigapixel whole slide images." Medical image analysis 76 (2022): 102298.
- [9].Oreiller, Valentin, et al. "Head and neck tumor segmentation in PET/CT: the HECKTOR challenge." Medical image analysis 77 (2022): 102336.
- [10].Roberts, Michael, et al. "Common pitfalls and recommendations for using machine learning to detect and prognosticate for COVID-19 using chest radiographs and CT scans." Nature Machine Intelligence 3.3 (2021): 199-217.
- [11].Kaissis, Georgios, et al. "End-to-end privacy preserving deep learning on multi-institutional medical imaging." Nature Machine Intelligence 3.6 (2021): 473-484.
- [12].Cichy, R.M., Roig, G. & Oliva, A. The Algonauts Project. Nat Mach Intell 1, 613 (2019).
- [13].LI X, CHEN H, QI X, *et al.* H-DenseUNet: hybrid densely connected UNet for liver and tumor segmentation from CT volumes[J]. IEEE Trans Med Imaging, 2018, 37(12): 2663-2674.
- [14] ZHAO X, WU Y, SONG G, *et al.* A deep learning model integrating FCNNs and CRFs for brain tumor segmentation[J]. Med Image Anal, 2018, 43: 98-111.
- [15] Azad R, Aghdam E K, Rauland A, et al. Medical image segmentation review: The success of u-net[J]. arXiv preprint arXiv:2211.14830, 2022.
- [16] Q. Li et al., "A Survey on Federated Learning Systems: Vision, Hype and Reality for Data Privacy and Protection," in IEEE Transactions on Knowledge and Data Engineering, vol. 35, no. 4, pp. 3347-3366, 1 April 2023, doi: 10.1109/TKDE.2021.3124599.
- [17] Lu S, Zhang Y, Wang Y. Decentralized federated learning for electronic health records[C]//2020 54th Annual Conference on Information Sciences and Systems (CISS).

IEEE, 2020: 1-5.)

[18] Xu X, Chen T, Deng H, et al. Federated cross learning for medical image segmentation[J]. arXiv preprint arXiv:2204.02450, 2022.

[19] Liu Q, Chen C, Qin J, et al. Feddg: Federated domain generalization on medical image segmentation via episodic learning in continuous frequency space[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 1013-1023.